

RAG 기반 주가 예측 추천 시스템 아키텍처 및 라이브러리 명세서

Retrieval-Augmented Generation (RAG) 시스템을 활용하여 주가 예측 추천 시스템을 구축하기 위한 프레임워크 및 라이브러리를 정리하였다. LlamaIndex 를 사용해 각 임베딩 간 코사인 유사도를 계산하여, 주가 예측과 관련된 자문 시스템을 구현하는 것을 목표로 한다.

1. 필요 프레임워크 및 라이브러리

데이터베이스 저장 (SQLite)

SQLite: 크롤링된 데이터를 저장하는 데이터베이스로, 크롤링된 주가 데이터를 효과적으로 저장하고 검색할 수 있는 환경을 제공한다.

임베딩 생성 (KF-DeBERTa)

KF-DeBERTa 는 카카오뱅크와 FnGuide 가 협력하여 개발한 한국어 금융 특화 언어모델이다. 금융 및 범용 도메인에서 뛰어난 성능을 목표로 설계되었으며, 금융 데이터를 포함한 대규모 학습 데이터로 사전학습(Pretraining)과 미세조정(Fine-tuning)을 거쳐 완성되었다.

벡터 DB 관리 및 검색 (Pinecone)

Pinecone: 벡터 데이터를 저장하고 유사성 검색을 수행하는 데 최적화된 벡터 데이터베이스이다. 임베딩된 벡터를 효율적으로 관리하고 검색할 수 있어, RAG 기반 주가 예측 추천 시스템에서 필수적인 역할을 한다. Pinecone 을 통해 KoBERT 모델로 생성된 임베딩 벡터를 저장하고 코사인 유사도를 기반으로 관련된 주가 예측 데이터를 제공한다.

질문 처리 및 검색 (LlamaIndex 및 기타 라이브러리)

1. LlamaIndex: LlamaIndex 는 임베딩 간의 코사인 유사도를 계산하여 주가 예측과 관련된 항목을 제공한다. Pinecone 과 연동하여 사용자가 입력한 주가 관련 질문에 대해 유사한 데이터 항목을 효과적으로 찾을 수 있다.
2. Scikit-learn: 벡터화된 데이터를 처리하는 데 유용한 수학적 함수와 유사도 계산 함수를 제공한다.

3. Numpy: 임베딩 벡터와 관련된 수학적 계산 및 유사도 측정을 빠르게 처리하여 코사인 유사도 계산에 활용된다.

응답 생성

1. OpenAI API: openai 패키지를 통해 LLM 을 호출하여 최종 답변을 생성한다. 사용자가 질문할 때, Pinecone 을 통해 검색된 주가 예측 데이터와 질문을 결합해 LLM 에게 전달하여 자연스러운 답변을 생성한다.

이 산출물에 포함된 프레임워크와 라이브러리는 주가 예측 자문 시스템을 구현하는 데 필요한 데이터 수집, 임베딩 생성, 벡터 DB 저장, 질문 검색, 그리고 답변 생성을 위한 최적의 선택지이다. 이를 통해 효율적인 RAG 기반 추천 시스템을 구축할 수 있으며, 개발에는 Visual Studio Code 를 코드 편집기로 사용할 예정이다.